



南开大学
Nankai University

南 开 大 学

计算机学院、密码与网络安全学院

软件工程

Lab3: 软件设计

姓名：熊诚义

学号：2313310

学院：计算机学院

指导老师：刘健

目录

一、 引言	1
(一) 编写目的	1
(二) 项目背景	1
(三) 使用工具	2
二、 用例图	3
(一) 用例图简介	3
(二) 用例图构建	3
1. 单细胞特征预处理子系统	3
2. 高维向量索引构建系统	4
3. 多租户混合检索系统	4
4. 索引生命周期管理系统	5
5. 多维可视化分析系统	5
(三) 用例图解释	5
1. 单细胞特征预处理子系统	5
2. 高维向量索引构建子系统	6
3. 多租户混合检索子系统	6
4. 索引生命周期管理子系统	6
5. 多维可视化分析子系统	7
三、 活动图	8
(一) 活动图简介	8
(二) 活动图构建	8
1. 用户登录与角色路由活动图	9
2. 单细胞数据预处理与向量入库活动图	9
3. ANN 索引构建与热加载活动图	11
4. 单细胞混合检索与可视化活动图	12
5. 批量检索与异步任务轮询活动图	12
(三) 活动图解释	13
1. 用户登录与角色路由流程	13
2. 单细胞数据预处理与向量入库流程	14
3. ANN 索引构建与热加载流程	14
4. 单细胞混合检索与可视化流程	14
5. 批量检索与异步任务轮询流程	14
四、 类图	16
(一) 类图简介	16
(二) 类图构建	16

(三) 类图解释	17
五、 顺序图	17
(一) 顺序图简介	17
(二) 顺序图构建	18
1. 用户注册与登录鉴权流程顺序图	18
2. 批量检索与异步任务轮询流程顺序图	19
3. 单细胞相似性检索流程顺序图	19
4. 数据预处理与向量入库流程顺序图	20
5. ANN 索引构建与热加载流程顺序图	21
(三) 顺序图解释	22
1. 用户注册与登录鉴权流程	22
2. 批量检索与异步任务轮询流程	23
3. 单细胞相似性检索流程	25
4. 数据预处理与向量入库流程	26
5. ANN 索引构建与热加载流程	27
六、 协作图	28
(一) 协作图简介	28
(二) 协作图构建	28
1. 用户注册与登录鉴权流程协作图	28
2. 批量检索与异步任务轮询流程协作图	29
3. 单细胞相似性检索流程协作图	29
4. 数据预处理与向量入库流程协作图	30
5. ANN 索引构建与热加载流程协作图	30
(三) 协作图解释	31
1. 用户注册与登录鉴权流程	31
2. 批量检索与异步任务轮询流程	31
3. 单细胞相似性检索流程	32
4. 数据预处理与向量入库流程	32
5. ANN 索引构建与热加载流程	32
七、 状态图	34
(一) 状态图简介	34
(二) 状态图构建	35
(三) 状态图解释	35
八、 构件图	37
(一) 构件图简介	37
(二) 构件图构建	38

(三) 构件图解释	38
九、 部署图	39
(一) 部署图简介	39
(二) 部署图构建	40
(三) 部署图解释	40

一、 引言

(一) 编写目的

在需求分析阶段，我们进行了深度调研与建模，明确了系统需处理千万级高维稀疏向量、严格平衡高召回率与毫秒级查询延迟等核心业务需求，确立了系统在处理单细胞异构数据时的功能边界。在软件设计阶段，我们的核心任务是实现从“业务逻辑模型”向“技术实现架构”的深度转化。我们不再停留于“系统做什么”的描述，而是通过对总体架构层次、高内聚功能模块、核心向量索引算法流程以及底层数据库逻辑结构的精确定义，解决高维空间索引构建的计算复杂度与内存消耗等工程痛点。本设计文档旨在将抽象的生物医学检索需求，转化为一套具备高鲁棒性、可扩展性且可指导实际编码的软件工程方案，为后续开发工作提供决定性的技术指引。

本文档编写的主要目的包括：

- 通过 UML 对系统进行深度建模，涵盖用例图、活动图、类图、顺序图等八种关键设计图示。我们要将需求阶段的“业务流”转化为程序运行的逻辑流程，规范底层检索引擎的对象层次与内存分布，精确定义高并发查询下的线程调度与资源争用逻辑，为可视化模块与检索内核的开发提供严密的编码指导。
- 在设计层级上明确划分数据预处理、向量索引、查询引擎及前端交互等子系统的职责边界，严格遵循“高内聚、低耦合”原则。帮助团队并行开发，有效识别并排除与高性能检索目标无关的边缘功能，防止项目在开发中后期出现功能性膨胀，确保系统资源始终聚焦于万级维度下的索引构建吞吐量。
- 针对单细胞测序数据普遍存在的“维度灾难”与高内存占用特征，本文档详细制定了乘积量化 (PQ) 索引方案、倒排索引空间压缩及预读缓存策略。我们对底层 I/O 路径与内存映射 (mmap) 机制的预演设计，确保系统在处理千万级规模向量数据时，能够从工程层面压制查询延迟的长尾效应，实现生产环境下 P99 延迟稳定在 500ms 以内的性能指标。
- 作为项目管理者、生物信息学专家与工程开发团队之间的关键技术方案，本文档将复杂的算法实现抽象为标准化的数据交互流程。保证相关人员对系统的物理部署拓扑达成共识，让非工程背景的成员能够理解从“生物序列查询”到“高维空间检索”的转化逻辑，确保各方对最终交付物的性能表现与交互行为有一致的预期。

(二) 项目背景

随着 10x Genomics 等高通量测序技术的成熟，单细胞研究的规模已实现从“数千个细胞”到“千万级乃至亿级细胞”的跨代跃升。数据规模的爆发式增长给底层的计算架构带来了前所未有的挑战。在计算表述上，每一个细胞被抽象为一个由 20,000 到 30,000 个基因表达值构成的高维特征向量。这类数据具有极高的维度和显著的稀疏性，伴随着生物实验特有的噪声。研究人员在进行细胞类型自动注释、病理样本比对以及药物响应预测时，核心需求是寻找与目标细胞特征最为相似的参考细胞，这在计算机科学领域是大规模高维向量空间的最近邻检索问题。

传统的精确检索算法在面对“维度灾难”时，搜索效率往往会退化至线性扫描的量级，导致单次查询耗时过长，无法支持临床实时诊断或大规模药物筛选场景。鉴于此，本项目拟研制的

“单细胞向量数据检索平台”，旨在通过软件工程的系统化设计，构建一套高性能的底层检索引擎。系统将针对单细胞数据的数学分布特征，定制近似最近邻算法，以期在千万级数据规模下实现毫秒级的响应。我们期望可以提升生物信息学家的科研效率，为精准医疗中的个体化辅助诊断、罕见细胞群发现以及细胞图谱的实时比对提供不可或缺的底层算力支撑。

(三) 使用工具

本文档使用 Overleaf 在线协作平台完成 LaTeX 编写与排版，文档中的系统建模图示遵循 UML 2.0 规范，主要绘图工具说明如下：

- **LaTeX (Overleaf)**：用于文档的版本控制与专业学术排版。
- **GitMind/ProcessOn**：用于绘制系统总业务流程图、用例图及活动图，直观展示业务逻辑与用户交互路径。
- **TikZ**：部分核心数据流图（DFD）与架构层次图通过 TikZ 宏包直接在 LaTeX 环境下编程生成，以保证矢量图在缩放下的精确度与一致性。
- **StarUML/Visual Paradigm**：用于构建严密的类图与顺序图，明确系统对象间的静态关系与动态调用时序。

二、 用例图

(一) 用例图简介

用例建模从外部视角描述系统的功能性需求，定义参与者（Actors）与系统产生的交互行为（Use Cases），确立了整个软件工程的逻辑边界。由于单细胞数据检索涉及生物学专家、算法工程师及系统管理员等多类干系人，用例图可以界定“系统应该做什么”以及“谁在驱动这些行为”。我们识别参与者并捕捉其理想行为，确保系统在处理千万级高维稀疏向量时，每一项计算资源的分配都直接服务于用户的业务目标。

在参与者的界定上，本项目根据实际应用场景将其划分为核心业务类与系统支撑类。临床医学诊断人员与基础医学实验人员构成了系统最主要的业务参与者，核心用例聚焦于“高维特征查询”与“细胞类型匹配”，要求系统提供直观的相似度反馈。向量检索引擎研发人员则通过“索引参数调优”与“算法性能压测”等用例与系统后端深度交互。

用例图可以通过明确的物理边界，将“湿实验”阶段的原始测序过程排除在软件处理范围之外，而将核心关注点锁定在“数字化向量的预处理、索引构建、近似最近邻检索及可视化呈现”这一完整链路，使开发团队集中精力优化检索引擎的吞吐量，不会陷入复杂的生物上游流程。

在本项目的设计方案中，用例图中定义的每一个交互点都将转化为顺序图中的对象消息传递，最终映射为类图中的成员函数。我们能够验证软件设计是否偏离了最初的性能指标。本章节的用例图既是业务流程的简化，也是“功能一致性”与“需求闭环”的约束准则。

(二) 用例图构建

1. 单细胞特征预处理子系统




图 1: 单细胞特征预处理子系统用例图

2. 高维向量索引构建系统




图 2: 高维向量索引构建系统用例图

3. 多租户混合检索系统




图 3: 多租户混合检索系统用例图

4. 索引生命周期管理系统




图 4: 索引生命周期管理系统用例图

5. 多维可视化分析系统




图 5: 多维可视化分析系统用例图

(三) 用例图解释

1. 单细胞特征预处理子系统

预处理业务流程由生信分析员上传异构原始数据文件（.h5ad 或 .loom 格式）正式开启。系统在接收到文件后，首先会自动触发数据合规性校验用例，解析文件头信息来识别数据模态，针

对多模态数据执行自动拆分。紧接着进入核心的质量控制（QC）阶段，系统会调用内置算子对每个细胞样本进行生存状态审计，包括计算线粒体基因占比、检测基因表达数量等，拦截并过滤掉空细胞、死细胞或双细胞等异常噪声。通过质控的样本将流入统计学标准化环节，系统会执行库大小归一化与对数转换，消除不同实验样本间的测序深度差异，随后启动批次效应矫正用例，通过算法移除不同实验批次产生的技术偏差。之后进入特征降维阶段，系统识别高变基因并应用 PCA 等流形学习技术，将成千上万维的稀疏矩阵投影为固定维度的稠密向量，生成该细胞唯一的“生物学指纹”。流程以生成可视化质量评估报告作为终点，用户确认预处理效果后，系统将这组标准化的特征向量序列打包移交给下游的索引构建引擎，完成从原始生物数据到数字化检索特征的闭环转化。

2. 高维向量索引构建子系统

接收到预处理后的稠密特征向量序列后，系统自动触发“环境感知与策略匹配”用例，探测当前服务器的内存余量、CPU 核心数及是否具备 GPU 加速条件，从算法库中自主选择最契合当前硬件约束的构建算子。之后流程进入“并行索引生产”阶段，系统同步执行空间切分与拓扑关系建立，利用多线程技术加速近邻图的边连接或聚类中心的收敛过程。在基础索引结构初步形成后，系统会自动调用“结构优化与压缩”用例，对冗余的图路径进行剪枝，执行向量量化压缩，在极小化内存占用的同时保证千万级数据下的检索召回率。最后一步是“索引挂载”，系统将优化后的索引文件映射至内存，向系统总控模块反馈索引就绪状态。

3. 多租户混合检索子系统

子系统先执行意图解析，将用户的检索请求拆分为“语义向量”与“标量过滤条件”两个维度。随后进入“并行检索过滤”环节，内部业务流分叉为两条同步路径：一方面调用向量引擎在索引结构中执行 Top-K 近邻搜索获取生物学特征最相似的候选集；另一方面根据用户定义的实验背景约束（如特定组织器官、样本供体年龄或测序平台等标量元数据），对数据库中的元数据执行布尔检索。之后流转至“结果位图交集运算”用例，系统在内存中利用位图索引将上述两路候选集进行快速合并，剔除不符合实验背景的干扰样本。最后执行“检索结果精排与封装”用例，根据多租户的安全隔离协议，将当前用户权限范围内且满足混合条件的细胞详情返回给前端展示界面。

4. 索引生命周期管理子系统

该流程由系统管理员手动发起，先执行增量数据注入，将待更新的单细胞特征向量暂存至缓冲区，同步开启后台计算线程执行“微索引构建”动作，避免对当前在线检索服务的干扰。当局部索引构建完成后，流程进入“原子化热切换”环节，用句柄替换机制将新旧索引在毫秒级内完成逻辑合并，确保检索链路的连续性。同时系统会执行数据效能监控，识别由于实验版本过旧或质量评估下降的陈旧数据，自动触发数据退役清理流程，将不常用的索引移出内存以释放资源。最后更新系统状态日志，确保在数据持续更迭中始终维持最优的响应速度与存储效率。

5. 多维可视化分析子系统

接收到检索系统推送的高相似度细胞集合后，该子系统自动实现空间坐标降维映射，将高维检索结果投影至二维交互平面，实现查询样本与参考图谱背景的重叠展示。随后进入交互式探索与比对内容，支持用户在可视化画布上执行点选、框选等交互动作，调取特定细胞的基因表达谱和实验背景信息，触发“聚类差异化分析”识别查询细胞与候选群体间的生物学一致性。之后我们的系统会提供结果标注与辅助诊断，根据相似度得分自动推断细胞类型并允许用户手动校正结果。最后子系统根据出版标准生成高分辨率的散点图、小提琴图及统计学分析报告，完成从数字化向量到直观科学结论的转化。

三、 活动图

(一) 活动图简介

活动图 (Activity Diagram) 是 UML 行为建模图的一种, 主要用于描述业务流程、系统处理流程以及不同活动之间的控制流转关系。活动图关注重点是一个业务从开始到结束经历了哪些动作、在哪些条件下发生分支、哪些处理可以并行执行, 以及异常情况如何回到主流程或提前终止。

在本系统中, 活动图承担着把需求分析阶段的业务流程转化为软件设计阶段可实现处理逻辑的作用。单细胞高维向量检索系统并不是简单的查询系统, 它同时包含用户鉴权、单细胞数据预处理、向量入库、ANN 索引构建、近似检索、元数据过滤、异步批量任务和可视化结果生成等多个连续环节。活动图可以把这些环节中的顺序执行、条件判断和并行处理显式表达出来, 使开发人员能够清楚判断每个功能入口之后系统应当执行哪些步骤。

活动图的绘制需要遵循 UML 基本规范。起始节点使用实心黑圆表示, 终止节点使用带外圈的终止圆表示; 具体业务操作使用圆角矩形动作节点表示, 节点名称应采用动作短语形式; 条件判断使用菱形决策节点表示, 从同一决策节点引出的控制流必须标注互斥条件; 并发流程使用粗横线表示分叉 (Fork) 与汇合 (Join); 当流程涉及多个职责主体时, 应使用泳道划分用户、前端、后端服务、数据库或索引引擎的责任边界。

本章节选取系统中最能体现核心业务价值和工程复杂度的五条流程绘制活动图, 分别为用户登录与角色路由流程、单细胞数据预处理与向量入库流程、ANN 索引构建与热加载流程、单细胞混合检索与可视化流程, 以及批量检索与异步任务轮询流程。这五张图覆盖了系统从“用户进入系统”到“数据变成可检索向量”、再到“索引上线并提供检索服务”的主要闭环。

(二) 活动图构建

本章节绘制五张 UML 活动图。绘图时统一使用 UML 活动图符号: 必须包含起始节点、终止节点、动作节点、控制流箭头、决策节点及必要的分叉/汇合节点; 对于涉及多角色协作的流程, 加入泳道以体现职责分工。

1. 用户登录与角色路由活动图

图 6 描述用户进入系统后完成身份认证、权限校验和角色路由的过程。该图的作用是明确所有业务功能的统一入口，保证后续检索、建库、调优和运维操作都建立在合法身份和正确角色权限之上。




图 6: 用户登录与角色路由活动图

2. 单细胞数据预处理与向量入库活动图

图 7 描述用户上传单细胞表达矩阵后，系统完成格式校验、质量控制、标准化、降维和向量持久化的完整流程。该图用于指导数据处理模块的实现，保证进入 ANN 索引的数据满足维度一致、质量可控和元数据可追溯的要求。




图 7: 单细胞数据预处理与向量入库活动图

3. ANN 索引构建与热加载活动图

图 8 描述公共数据库管理人员或检索引擎研发人员触发索引构建后，系统执行参数配置、并行构建、质量验证和在线热加载的过程。该图用于体现索引生命周期管理中的并发构建、召回率验证和原子化切换机制。




图 8: ANN 索引构建与热加载活动图

4. 单细胞混合检索与可视化活动图

图 9 描述用户提交单个查询向量或细胞样本后，系统并行执行 ANN 近似检索与元数据过滤，并将 Top-K 结果返回前端进行列表展示、UMAP/t-SNE 可视化或诊断报告导出的过程。




图 9: 单细胞混合检索与可视化活动图

5. 批量检索与异步任务轮询活动图

图 10 描述生物信息学人员或基础医学实验人员提交批量检索任务后，系统创建异步任务、拆分子任务、并行执行检索、汇总结果，并由客户端轮询任务状态直至获取结果文件的过程。该

图用于体现长耗时任务的非阻塞设计。




图 10: 批量检索与异步任务轮询活动图

(三) 活动图解释

1. 用户登录与角色路由流程

该活动图从用户打开系统登录页开始，首先由用户提交账号和密码，系统随后对账号存在性、密码哈希值和账号锁定状态进行统一校验。若认证失败，系统返回错误提示，并通过决策节点判断用户是否继续尝试登录；若用户放弃，则流程直接进入终止节点。该分支体现了活动图中异常路径必须被显式表达的要求。

认证通过后，系统签发会话 Token，并读取用户的角色类型与权限范围。角色路由节点将用户分流到三类工作台：临床医学诊断人员、基础医学实验人员和生物信息学人员进入检索与分析工作台；向量检索引擎研发人员和公共数据库管理人员进入数据建库与算法调优后台；系统运维人员进入运维监控控制台。不同分支最终汇合到“执行对应业务操作”，说明所有角色虽然功能入口不同，但都遵循统一的登录、授权和退出机制。

2. 单细胞数据预处理与向量入库流程

该活动图描述原始单细胞数据从上传到转化为可检索向量的全过程。用户上传 .h5ad 或 .mtx 等标准格式文件后，系统先进行格式、字段完整性和租户权限校验。若文件格式错误或用户无权操作对应数据集，系统直接拒绝入库并结束流程，避免无效数据进入后续计算链路。

校验通过后，系统解析表达矩阵和细胞元数据，并进入质量控制阶段。质控活动包括过滤空细胞、异常低质量细胞、疑似双细胞以及线粒体基因占比异常的细胞样本。若质控失败，系统生成报告并结束；若质控通过，则继续执行归一化、对数转换、批次效应矫正和 PCA 降维，最终生成固定维度的稠密特征向量。最后系统将细胞元数据、向量数组和预处理参数一并写入数据库，为后续索引构建提供稳定输入。

3. ANN 索引构建与热加载流程

该活动图体现索引构建不是单一计算动作，而是包含数据检查、参数配置、并行构建、质量验证和上线发布的完整生命周期。管理员首先选择待建索引的数据集，系统检查向量完整性、维度一致性和当前资源配额；若数据不满足构建条件，则返回数据修复或重新预处理流程。

数据就绪后，系统根据数据规模和性能目标配置 ANN 算法类型、距离度量和超参数。活动图中使用分叉节点表示多个并行活动：一条路径负责分片读取向量数据，一条路径负责并行构建 HNSW、IVF 或其他 ANN 索引结构，另一条路径负责记录构建进度和资源消耗。三条路径在汇合节点同步后，系统执行索引压缩、序列化和校验，并通过基准查询评估召回率与查询延迟。若指标不满足要求，流程回到参数调整；若满足要求，则将索引热加载到在线检索服务并标记为 Ready。

4. 单细胞混合检索与可视化流程

该活动图是系统在线检索能力的核心表达。用户通过 Web 页面或 API 提交查询向量、Top-K 参数和元数据过滤条件后，系统先校验 Token、租户权限和查询配额，再检查索引是否处于 Ready 状态以及查询向量维度是否与索引一致。任何权限错误、参数错误或索引未就绪情况都会进入异常结束路径，防止产生不可信结果。

通过基础校验后，流程进入并行处理阶段：一条分支调用 ANN 索引执行 Top-K 候选检索，另一条分支根据组织来源、供体信息、测序平台等标量条件执行元数据过滤。两条分支汇合后，系统对候选集和过滤集进行交集运算，再执行距离精排与元数据关联，形成可解释的细胞匹配结果。随后系统保存检索任务记录，包括查询快照、结果 JSON、可视化坐标和执行耗时。若用户需要可视化展示，系统生成 UMAP/t-SNE 散点图或诊断报告；若不需要，则直接返回 Top-K 列表和统计指标。

5. 批量检索与异步任务轮询流程

该活动图用于描述长耗时批量任务的异步执行逻辑。用户提交批量查询文件或 API 请求后，系统首先进行格式、维度和权限校验。校验失败时直接返回错误，避免后台任务队列被无效请求占用；校验成功时，系统创建异步任务并立即返回 task_id，使客户端不需要阻塞等待完整结果。

后台服务将批量查询拆分为多个子任务并写入任务队列，然后通过分叉节点交由多个工作进程并行执行子检索。所有工作进程完成后在汇合节点同步，系统汇总子任务结果并计算总体进度。若任务尚未全部完成，客户端继续轮询任务状态；若所有子任务完成，系统生成 JSON 或 CSV 结果文件，并通知用户下载。该设计满足需求分析中对批量检索、API 调用和后台任务可跟踪性的要求。

四、 类图

(一) 类图简介

类图从内部逻辑视角描述系统的静态结构，定义了系统内核心业务的数据实体（Classes）、属性以及实体间产生的关联关系，确立了整个软件工程的数据底座。由于单细胞数据检索涉及海量实体与复杂的底层算法，类图可以清晰界定“系统由哪些核心领域模型构成”以及“数据在实体模型间如何流转与维系”。我们识别关键对象模型并捕捉其基数依赖，确保系统在处理千万级高维稀疏向量时，底层的存储模型与对象关系能够直接支撑业务侧对高性能存取的需求。

在核心对象的界定上，本项目根据实际数据流转生命周期将其划分为基础业务类与算法支撑类。用户信息（UserInfo）、数据集信息（DatasetInfo）与细胞特征信息（CellInfo）构成了系统的客观数据载体，完整保留了多维度生物测序产生的结构化元数据。而向量表示（VectorEmbedding）、近似最近邻索引（ANNIndex）与检索任务（SearchTask）则属于核心算法支撑实体，将降维后的稠密特征数据与结构化引擎深度绑定，要求系统提供具备高空间局部性与低延迟存取特性的内存表现形式。

类图可以通过明确的关联聚合边界，将底层繁杂的文件 I/O 细节与具体的数据库增删改查逻辑进行合理的面向对象封装，而将核心关注点锁定在“细胞、特征向量、索引架构及查询任务”这一高度内聚的领域模型拓扑中。这使得开发团队在实现系统底座时，能集中精力优化核心对象的关联查询路径以及大规模索引对象的序列化构建，而不会陷入无关的物理存储碎片中。

在本项目的设计方案中，类图中定义的每一个实体与其包含的参数字段，都将转化为数据字典中的关系型表或结构化文档，类与类之间的单向发起与多重包含关联，最终严格映射为数据库中的主外键约束体系。我们能够借此验证静态架构是否足以支撑顺序图中的并发调用，并是否满足了最初低延迟检索的性能指标。本章节的类图既是后期代码抽象与数据库搭建的模型蓝图，也是检验整个系统“架构合理性”与“数据完整性”的基石准则。

(二) 类图构建




图 11: 系统核心数据字典 UML 类图

(三) 类图解释

图 11 所展示的 UML 类图从静态数据结构的视角,全局刻画了本系统核心业务模型库的实体组成及其内在的拓扑映射关系。整个数据底座由六大核心逻辑类构成,其中“用户信息 (UserInfo)”作为驱动业务流转的顶层参与者,向下同时维系着数据构建与检索应用两条主线:一方面,用户作为数据所有者负责上传和注册“数据集 (DatasetInfo)”,数据集在逻辑域内通过主外键严格包含海量的底层“细胞信息 (CellInfo)”,并进一步向下衍生出用于算法计算的高维“向量表示 (VectorEmbedding)”,构成了严密的数据导入流水线;另一方面,在核心的检索引擎支撑层面,用户可基于特定的数据集配置并实例化“近似最近邻索引 (ANNIndex)”,进而发起指向该索引架构的“检索任务 (SearchTask)”,实现业务闭环。

在该对象关系建模中,各实体间的连线及其多重度(如 1 对多引用)清晰界定了不同领域对象间的归属依赖与基数限制,将原本扁平的数据字典字段通过逻辑实体关联紧密缝合在一个完整的连通图中。例如,高频的检索任务模块被要求强制指明其查询的索引本体,以及特征维度数据对上层实体表的级联依赖等设计,不仅从逻辑边界上剥离了不同服务间的耦合,更为系统后续在关系型数据库中的物理表结构搭建、联表查询分析优化以及领域驱动代码的开发提供了可靠且明确的架构蓝图。

五、 顺序图

(一) 顺序图简介

顺序图 (Sequence Diagram) 是 UML 行为图的核心组成之一,用于从时间维度描述系统内部各对象之间的动态交互过程。与用例图聚焦于“系统做什么”、类图聚焦于“系统由什么构成”不同,顺序图的核心价值在于精确刻画“谁在何时向谁发送了什么消息”,将系统中散布于各模块的协作逻辑压缩为一张具有强时序约束的交互快照。

顺序图的基本构成要素如下:

- **参与者 (Actor) 与对象 (Object)**: 图顶部横向排列的各个方块,代表参与本次交互的外部用户或系统内部对象实例。每个对象下方延伸出一条垂直的**生命线 (Lifeline)**,表示该对象在时间轴上的存活区间。
- **激活条 (Activation Bar)**: 叠加在生命线上的窄矩形,表示该对象正在执行某一操作的时间段,直观反映系统内各对象的并发与串行关系。
- **消息 (Message)**: 连接两条生命线之间的带箭头横线,是顺序图的核心元素。实线箭头表示同步调用,即调用方阻塞等待返回;虚线箭头表示返回消息;异步消息则以开放箭头标注。
- **组合片段 (Combined Fragment)**: 用于表达条件分支 (alt)、循环 (loop)、并行 (par) 等复杂控制流逻辑的矩形框,弥补了简单消息序列在表达复杂流程时的局限。

在本单细胞向量数据检索平台中,顺序图的引入具有三方面核心价值。其一,系统涉及多个高内聚子模块的跨层调用,包括 Web 前端、业务引擎层、向量索引模块与数据库,顺序图能够

将这些模块之间隐式的调用时序显式化，为开发团队提供精确的接口契约；其二，系统中存在多个性能敏感的关键路径，如并行检索过滤、ANN 索引加载等，通过顺序图可以精确标注各阶段的消息边界，为后续的性能压测与优化提供可量化的参照；其三，将顺序图与类图、用例图等相互印证，可以有效验证系统的静态结构设计是否足以支撑动态运行时的协作需求，确保整体设计的逻辑闭环。

本章节选取了系统中最具代表性的五条核心业务链路分别绘制顺序图，涵盖用户注册与登录鉴权流程、批量检索与异步任务轮询流程、用户发起单细胞相似性检索的完整调用链、数据预处理与向量入库流程，以及 ANN 索引的构建与热加载流程，以全面呈现系统运行时的内部协作逻辑。

(二) 顺序图构建

1. 用户注册与登录鉴权流程顺序图

图 12 描述了新用户完成账号注册、老用户凭密码登录并经系统签发 Token 后被路由至对应功能工作台的完整鉴权时序，覆盖连续登录失败触发账号锁定的异常分支。该流程是系统所有其他功能链路的安全入口，其正确性直接决定多租户隔离与权限管控机制的可靠性。




图 12: 用户注册与登录鉴权流程顺序图

2. 批量检索与异步任务轮询流程顺序图

图 13 描述了生物信息学人员通过 API 客户端提交批量检索请求，系统后台将任务拆解并行执行，客户端通过指数退避轮询机制持续查询任务状态，直至获取完整 JSON 结果并写入下游分析流水线的完整异步交互时序。




图 13: 批量检索与异步任务轮询流程顺序图

3. 单细胞相似性检索流程顺序图

图 14 描述了用户（以临床医学诊断人员为典型代表）通过 Web 界面发起一次单次向量检索请求，直至系统返回 Top-K 相似细胞并完成前端展示的完整调用时序。




图 14: 单细胞相似性检索流程顺序图

4. 数据预处理与向量入库流程顺序图

图 15 描述了基础医学实验人员上传原始单细胞数据文件后，系统执行格式校验、生物学质量控制、特征降维，并最终将稠密特征向量持久化入库的完整后台处理时序。




图 15: 数据预处理与向量入库流程顺序图

5. ANN 索引构建与热加载流程顺序图

图 16 描述了公共数据库管理人员触发全量 ANN 索引构建任务, 系统完成参数配置、并行构建、召回率验证与原子化热切换上线的完整时序。




图 16: ANN 索引构建与热加载流程顺序图

(三) 顺序图解释

1. 用户注册与登录鉴权流程

该顺序图共涉及四个参与方：用户 (User)、Web 前端 (WebInterface)、用户认证服务 (AuthService) 以及 用户数据库 (UserDB)。

整个交互流程分为注册与登录两条并列子路径，以及贯穿始终的异常处理分支，共五个阶段。

(1) **新用户注册** 首次访问系统的用户在 WebInterface 的注册页面填写用户名 (username)、登录密码、所属机构 (institution) 及角色类型 (role_type, 从六类预定义角色中选择)，点击“注册”后，WebInterface 将注册表单封装为 POST /register 请求发送至 AuthService。AuthService 首先向 UserDB 发起 checkUsernameUnique 查询，确认用户名全局唯一；若已存在同名账号，立即向 WebInterface 返回 409 Conflict 响应，提示用户更换用户名。唯一性校验通过后，AuthService 对原始密码执行加盐哈希处理 (Argon2 或 bcrypt 算法)，生成 password_hash，并根据 role_type 自动分配对应的默认存储配额 (storage_quota)。随后 AuthService 向 UserDB 写入完整的用户记录，包括系统自动生成的 user_id、created_at 时间戳及上述所有字段，数

数据库任何位置均不保存明文密码。写入成功后, AuthService 向 WebInterface 返回注册成功响应, 前端引导用户跳转至登录页面, 注册子流程结束。

(2) 登录凭据校验 已注册用户在登录页面输入用户名与密码后, WebInterface 将凭据封装为 POST /login 请求发送至 AuthService。AuthService 向 UserDB 发起 getUserByUsername 查询, 获取该账号的 password_hash、role_type 及当前账号状态 (正常/锁定)。若账号不存在, 返回 404 Not Found; 若账号已被锁定, 返回 423 Locked 并告知锁定剩余时间, 终止流程。账号状态正常时, AuthService 对用户输入密码执行同算法哈希运算后与存储值进行比对。若哈希值不匹配, AuthService 向 UserDB 写入本次失败记录, 递增连续失败计数; 当失败计数达到 3 次时, AuthService 触发账号临时锁定, 向 UserDB 写入锁定状态与锁定截止时间, 并向 WebInterface 返回 423 Locked 响应, 阻断后续所有来自该账号的登录请求。

(3) Token 签发 密码比对通过后, AuthService 生成具有时效的会话 Token, Token 载荷中编码 user_id、role_type 及过期时间戳 (有效期 3 天)。AuthService 将 Token 明文返回给 WebInterface, WebInterface 将其持久化存储于浏览器安全存储区, 后续所有功能请求均在 HTTP Header 的 Authorization 字段中携带该 Token, 实现无状态鉴权, 无需重复登录。与此同时, AuthService 向 UserDB 更新该账号的最后登录时间, 并将连续失败计数重置为零。

(4) 角色路由与工作台加载 WebInterface 接收到 Token 后, 从 AuthService 的响应体中读取 role_type 字段, 依据六类角色执行前端路由跳转: 临床医学诊断人员进入检索诊断工作台, 基础医学实验人员进入批量查询工作台, 生物信息学人员进入 API 开发者中心, 向量检索引擎研发人员进入性能调优看板, 数据库管理人员进入数据建库中心, 系统运维人员进入硬件监控大盘。对于用户权限范围之外的功能模块, WebInterface 动态隐藏对应菜单项, 后端 AuthService 对所有后续请求中的 Token 持续校验, 对越权调用统一返回 403 Forbidden, 确保权限校验不依赖前端界面的显隐逻辑。

(5) Token 续期与安全退出 在用户会话期间, WebInterface 周期性检测 Token 剩余有效期; 当有效期不足 30 分钟时, 前端静默向 AuthService 发起 POST /token/refresh 请求, AuthService 验证旧 Token 合法性后签发新 Token 并返回, 实现无感知续期。用户主动点击退出时, WebInterface 向 AuthService 发送 POST /logout 请求, AuthService 将该 Token 加入服务端黑名单或清除服务端 Session 记录, WebInterface 同步清除本地存储的 Token, 跳转至登录页面, 本次会话安全终止。

2. 批量检索与异步任务轮询流程

该顺序图共涉及五个参与方: **API 客户端 (APIClient)**、**任务队列 (TaskQueue)**、**检索工作进程 (SearchWorker)**、**向量数据库 (VectorDB)** 以及 **任务数据库 (TaskDB)**。

整个交互流程分为以下五个阶段:

(1) 批量请求提交与任务入队 生物信息学人员在本地编程环境 (Python/R 脚本) 中将待检索的多条查询向量及对应的检索参数 (`top_k`、`ef_search`、元数据过滤条件、目标索引 ID) 打包为符合接口规范的 JSON 格式, 在 HTTP Header 中携带长期有效的 API Token, 以 `POST /batch-search` 的形式同步发送至系统网关。系统网关完成 Token 校验后, 将请求转发至 TaskQueue。TaskQueue 为本次批量任务生成全局唯一的 `batch_task_id`, 将任务状态初始化为 `Pending`, 并将整批查询向量序列化后写入任务持久化队列。TaskQueue 立即向 APIClient 返回包含 `batch_task_id` 的 202 Accepted 响应, 确认任务已入队, 不阻塞等待实际执行结果, 使客户端可以继续进行其他操作。

(2) 任务拆解与并行子任务分发 TaskQueue 后台调度器检测到新任务入队后, 将批量任务按配置的分片策略, 例如每片 500 条查询向量, 拆解为若干独立子任务, 为每个子任务分配唯一的 `sub_task_id`, 并将所有子任务状态更新为 `Running`, 写入 TaskDB。调度器将各子任务并行分发至多个 SearchWorker 进程实例执行, 充分利用服务器多核计算资源。SearchWorker 接收到子任务后, 向 TaskDB 写入子任务开始执行的时间戳, 随即进入实际检索阶段。

(3) 子任务向量检索执行 每个 SearchWorker 独立执行所分配子批次中每条查询向量的完整检索链路: 首先向 VectorDB 调用 `getNormalizationParams` 获取归一化参数, 对查询向量执行对齐预处理; 随后调用 VectorDB 的 `annSearch` 在目标 ANN 索引上执行 `Top-K×2` 粗筛检索, 获取候选集; 对候选集执行精确重排序后截取最终 `Top-K` 结果; 最后调用 VectorDB 的 `getCellMetadata` 批量查询每条结果的生物学元数据标签, 完成结果富化。子批次全部检索完成后, SearchWorker 将本批次的结构化结果 (每条查询向量对应的 `Top-K` 细胞 ID 列表、距离分值、元数据标签及子任务执行耗时) 写入 TaskDB 的对应子任务记录, 并将子任务状态更新为 `Completed`。若某条查询向量出现维度不匹配或向量格式异常, SearchWorker 将该条目标记为 `Failed` 并记录具体错误原因, 不影响同批次其余查询的正常执行。

(4) 客户端指数退避轮询 APIClient 在提交批量任务后, 脚本中预设的轮询逻辑以 `GET /tasks/{batch_task_id}` 接口定期查询任务状态。为避免对服务端造成不必要的请求压力, 轮询采用指数退避策略: 初始等待间隔为 1 秒, 此后每次轮询间隔翻倍 (`1s → 2s → 4s → 8s`), 直至达到设定的最大间隔上限, 例如 60 秒后维持恒定频率轮询。TaskQueue 接收到状态查询请求后, 聚合 TaskDB 中所有子任务的执行状态, 计算整体完成进度百分比, 以 `{"status": "Running", "progress": 67}` 格式返回给 APIClient。若网络超时或服务端返回 5xx 错误, APIClient 脚本中的重试机制自动触发, 在当前退避间隔内重新发起请求, 最多重试 5 次; 超过重试上限后记录失败日志并向用户抛出异常。

(5) 结果汇总、交付与下游集成 当 TaskDB 中所有子任务均达到终态 (`Completed` 或 `Failed`) 时, TaskQueue 触发结果汇总流程: 将所有子任务的结果按原始查询向量的提交顺序重新排列合并, 生成完整的批量检索结果集, 将整体任务状态更新为 `Completed`, 并将汇总结果 (`result_json`) 写入 TaskDB 的主任务记录。APIClient 的下一轮次轮询收到 `"status": "Completed"` 响应后, 从响应体中直接读取完整的 `result_json`, 或通过 `GET /tasks/{batch_task_id}/result` 接口

下载结果文件。APIClient 脚本自动解析 JSON 响应，将每条查询对应的 Top-K 匹配列表、距离分值及生物学元数据标签写入下游分析流水线的下一环节（如 R/Python 的 AnnData 对象或 CSV 文件），同时对接收数据执行完整性校验（结果条数、向量维度一致性、元数据字段无缺失），确认无误后安全关闭本次 API 会话，批量检索流程正式结束。

3. 单细胞相似性检索流程

该顺序图共涉及五个参与方：用户（User）、Web 前端（WebInterface）、搜索引擎（SearchEngine）、向量引擎（VectorDB）以及元数据数据库（MetaDB）。

整个交互流程分为以下六个阶段：

(1) 请求接入与参数解析 用户在前端填写查询参数（包括查询向量或目标细胞编号、Top-K 值、元数据过滤条件及目标索引 ID），点击“开始检索”后，WebInterface 将请求封装为标准 JSON 格式，携带 API Token，以 POST /search 的形式同步发送至 SearchEngine。SearchEngine 接收请求后，首先从 Token 中解析出发起用户的 user_id 与 role_type，完成权限校验，确认用户对目标数据集具有访问权限。

(2) 查询向量预处理 权限校验通过后，SearchEngine 向 VectorDB 发起 getNormalizationParams 调用，获取目标索引所对应的归一化参数（均值、标准差等）。SearchEngine 将用户提交的原始查询向量按照这组参数进行对齐变换，确保其与索引空间处于同一流形，随后校验向量维度与目标索引维度的一致性；若维度不一致，立即向 WebInterface 返回 400 Bad Request 错误响应，终止流程。

(3) 并行检索过滤 维度校验通过后，SearchEngine 内部触发并行执行的两条子路径。路径一调用 VectorDB 的 annSearch 方法，在已驻留内存的 ANN 索引上执行 Top-K×2 的粗筛候选集检索，利用 HNSW/IVF 等索引结构的亚线性复杂度快速锁定近似最近邻候选。路径二同时向 MetaDB 发起 filterByMetadata 调用，依据用户设定的标量过滤条件（如 tissue_type = 'Lung'、sequencing_platform = '10x Genomics' 等）执行布尔索引过滤，获取满足条件的细胞 ID 位图集合。SearchEngine 收集到两路结果后，执行位图交集运算，剔除不符合元数据约束的候选向量，缩减精排范围。

(4) 精确重排序 对交集候选集中的每一个细胞，SearchEngine 从 VectorDB 调用 getEmbedding 获取其原始特征向量，与查询向量逐一计算精确距离（L2 欧氏距离或余弦相似度），并按距离升序排列，截取最终的 Top-K 结果。精排阶段的引入弥补了 ANN 粗筛阶段由量化压缩或图剪枝带来的召回损失，确保最终返回结果的精度满足 95% 的召回率约束。

(5) 元数据富化与任务记录 精排完成后，SearchEngine 向 MetaDB 发起 getCellMetadata 批量查询，为每条 Top-K 结果附加 cell_type_label、tissue_type、donor_id 等生物学元数据标签，完成结果富化。随后 SearchEngine 将本次检索的完整记录（查询向量快照、检索参数、

result_json、visualization_coords、execution_time) 异步写入 MetaDB 的 search_tasks 表, 生成唯一 task_id 供后续查询与审计。

(6) 结果返回与前端渲染 SearchEngine 将富化后的 Top-K 结果封装为 JSON 响应体, 连同 task_id 和 execution_time 一并同步返回给 WebInterface。WebInterface 接收响应后, 渲染结构化检索结果列表, 并驱动前端 WebGL 引擎读取 visualization_coords 字段, 在 UMAP 散点图中高亮标注查询细胞及 Top-K 匹配结果, 完成本次交互。

4. 数据预处理与向量入库流程

该顺序图共涉及四个参与方: **用户 (User)**、**Web 前端 (WebInterface)**、**数据处理模块 (DataProcessor)** 以及 **数据库 (Database)**。

整个交互流程分为以下四个阶段:

(1) 文件上传与合规性校验 用户通过 WebInterface 选择本地的 .h5ad 或 .loom 格式文件, 发起分块上传请求。WebInterface 采用断点续传机制, 将文件分块传输至 DataProcessor, 由 DataProcessor 拼接并写入服务器临时存储, 同时返回上传进度至前端实时展示。文件接收完毕后, DataProcessor 自动执行第一阶段校验: 解析文件头部信息, 验证文件格式合法性、矩阵维度完整性及基因列表与细胞编号的唯一性, 并将数据集基本信息 (matrix_file_path、gene_list、cell_count) 写入 Database 的 expression_metadata 表。若格式校验失败, DataProcessor 立即向 WebInterface 返回详细错误报告, 终止后续流程并提示用户修复后重新上传。

(2) 生物学质量控制 (QC) 格式校验通过后, DataProcessor 进入第二阶段的生物学质控流程。系统对矩阵中的每个细胞依次执行: 空细胞过滤 (总计数为零的细胞予以剔除)、双细胞检测 (标注异常高计数的疑似双细胞)、线粒体基因占比计算 (超过阈值的受损细胞予以过滤)。质控完成后, DataProcessor 统计矩阵稀疏度 (sparsity_ratio) 并将质控结果 (通过细胞的 cell_id 列表、tissue_type、sequencing_platform 等元数据字段) 写入 Database 的 cell_metadata 表, 同时向 WebInterface 推送质控摘要报告。若质控严重不达标, 系统标记数据集为无效状态并终止流程; 若部分细胞未通过质控, 系统继续以通过质控的细胞子集为输入推进后续流程。

(3) 特征降维与向量生成 质控通过后, DataProcessor 启动特征提取流水线: 首先对矩阵执行库大小归一化与对数转换, 消除测序深度差异; 随后识别高变基因子集, 将特征空间从全量数万个基因压缩至高变基因子空间; 最后调用降维算法 (PCA、VAE 或 scVI, 由用户在上传时选定), 将高维稀疏矩阵投影为固定维度的稠密特征向量。降维完成后, DataProcessor 将每个细胞的 embedding_data (Binary 格式浮点向量)、dimension、reduction_method 及 normalization_params 批量写入 Database 的 cell_vectors 表, 并向 WebInterface 返回预处理完成通知及质量评估报告摘要, 提示用户可进入索引构建阶段。

(4) 状态更新与用户确认 DataProcessor 将数据集状态更新为“已完成预处理”, 并在 Database 中记录本次预处理的时间戳和统计指标 (有效细胞数、最终向量维度等)。WebInterface 收到通

知后展示预处理质量报告，用户核认无误后可手动触发后续的 ANN 索引构建任务，从而启动下一阶段的处理链路。

5. ANN 索引构建与热加载流程

该顺序图共涉及五个参与方：管理员 (Admin)、系统总控模块 (SystemController)、索引构建引擎 (IndexBuilder)、向量数据库 (VectorDB) 以及 在线检索服务 (SearchService)。

整个交互流程分为以下四个阶段：

(1) 构建参数配置与任务提交 管理员在后台管理中心配置本次索引构建任务的参数，包括索引算法类型 (HNSW、IVF_PQ 或 ScaNN)、距离度量方式 (L2、Cosine 或 IP) 以及算法超参数 (HNSW 的 M 值与 `ef_construction`，或 IVF 的 `nlist` 与量化段数)，并指定目标数据集 ID。SystemController 接收到构建指令后，将任务入队并将 `build_status` 初始化为 `Building`，写入 VectorDB 的 `ann_indices` 表，随后向 IndexBuilder 发起异步构建调用，同时向管理员返回 `task_id` 确认消息。

(2) 向量读取与并行索引生产 IndexBuilder 收到构建指令后，向 VectorDB 批量读取目标数据集中所有细胞的 `embedding_data`，同时探测当前服务器的硬件环境（内存余量、CPU 核数、GPU 可用性），从算法库中自主匹配最契合当前硬件约束的构建算子。随后 IndexBuilder 启动多线程并行索引生产：HNSW 类型的索引以多线程并发方式构建分层导航图结构，执行边连接与近邻图剪枝；IVF_PQ 类型的索引则并行执行聚类中心计算与乘积量化压缩，在极小化内存占用的同时保证检索召回率。IndexBuilder 在构建过程中定期向 SystemController 汇报进度百分比，SystemController 将进度信息实时推送给管理员的监控看板。

(3) 召回率验证与质量审核 构建完成后，IndexBuilder 将索引序列化为二进制文件，写入磁盘并将 `index_file_path` 更新至 VectorDB。随后 IndexBuilder 自动执行基准召回率验证：在标准测试集上针对新索引执行 Top-100 检索，计算实际召回率，并与 95% 的最低阈值进行比对。若召回率达标，IndexBuilder 将 `build_status` 更新为 `Ready` 并通知 SystemController；若召回率不达标，将状态标记为 `Error` 并附带详细的性能诊断报告，由管理员决定是否调整超参数后重新构建。

(4) 原子化热切换与服务上线 SystemController 收到 `Ready` 通知后，向 SearchService 发起索引热切换指令。SearchService 采用句柄替换机制，在毫秒级内将内存中的旧索引引用原子性地替换为新索引实例，完成逻辑切换，整个过程对正在执行中的检索请求透明无感知，不产生服务中断。切换完成后，SearchService 向 SystemController 反馈就绪状态，SystemController 将索引版本号与上线时间记录至系统日志，并向管理员推送索引上线成功通知，本次构建流程正式结束。旧索引内存资源在所有持有其引用的飞行中请求全部处理完毕后，由系统自动异步回收，保障内存使用的安全与高效。

六、 协作图

(一) 协作图简介

协作图又称通信图，是 UML 交互图的一种，用于描述系统运行过程中对象之间如何通过消息传递完成某一业务功能。与顺序图相比，协作图不再把重点放在严格的纵向时间轴上，而是更强调参与对象之间的结构关系、调用路径以及对象之间的协作方式。通过在对象之间的链路上标注带编号的消息，协作图既能保留交互发生的先后顺序，又能更直观地展示系统内部各模块之间的依赖关系。

在本系统中，协作图主要用于承接顺序图部分已经定义的五条核心业务链路。每张协作图均围绕一个典型用例展开，展示外部用户、前端界面、后端服务、向量数据库、元数据数据库、任务队列等对象如何相互调用。图中的消息编号与顺序图中的调用阶段保持一致，用以说明同一业务过程在对象结构视角下的实现方式。

协作图的基本组成元素包括：

1. 对象：表示参与本次交互的系统实体或模块，例如 Web 前端、认证服务、搜索引擎、向量数据库等。
2. 链路：表示对象之间存在通信关系，是消息传递的基础。
3. 消息：表示对象之间发起的调用、查询、状态更新或结果返回，一般标注在链路上。
4. 消息编号：表示消息发生的先后次序。对于嵌套调用，可使用 1.1、1.2 等形式表达层级关系。
5. 条件说明：对于异常分支、状态判断、循环轮询等复杂控制逻辑，可以通过消息标签或注释说明。

(二) 协作图构建

1. 用户注册与登录鉴权流程协作图

图 17 中包含用户、Web 前端、用户认证服务和用户数据库四个对象，重点展示注册、登录、Token 签发、Token 续期与安全退出过程中的对象协作关系。




图 17: 用户注册与登录鉴权流程协作图

2. 批量检索与异步任务轮询流程协作图

图 18 包含 API 客户端、任务队列、检索工作进程、向量数据库和任务数据库五个对象，重点展示批量任务入队、任务拆分、并行检索、状态轮询和结果汇总的协作关系。




图 18: 批量检索与异步任务轮询流程协作图

3. 单细胞相似性检索流程协作图

图 19 包含用户、Web 前端、搜索引擎、向量数据库和元数据数据库五个对象，重点展示一次在线 Top-K 相似细胞检索中，权限校验、向量归一化、ANN 粗筛、元数据过滤、精排、结果

富化与前端展示的完整协作关系。




图 19: 单细胞相似性检索流程协作图

4. 数据预处理与向量入库流程协作图

图 20 包含用户、Web 前端、数据处理模块和数据库四个对象，重点展示原始单细胞文件上传、格式校验、质量控制、特征降维、向量持久化和用户确认的协作关系。




图 20: 数据预处理与向量入库流程协作图

5. ANN 索引构建与热加载流程协作图

图 21 包含管理员、系统总控模块、索引构建引擎、向量数据库和在线检索服务五个对象，重点展示索引构建参数配置、任务提交、向量读取、并行构建、召回率验证、索引状态更新和原子化热切换的协作关系。




图 21: ANN 索引构建与热加载流程协作图

（三） 协作图解释

1. 用户注册与登录鉴权流程

用户注册与登录鉴权协作图展示了系统安全入口的对象协作方式。用户首先通过 Web 前端提交注册信息或登录凭据，WebInterface 负责将表单数据封装为标准 HTTP 请求并转发给 AuthService。AuthService 是该流程中的核心控制对象，负责用户名唯一性检查、密码哈希处理、登录凭据校验、失败次数记录、账号锁定以及 Token 签发等操作。UserDB 则作为持久化对象，保存用户基础信息、密码散列值、角色类型、账号状态和登录失败次数。

该协作图中的异常分支与顺序图保持一致：当注册用户名已存在时，系统返回 409 Conflict；当登录账号不存在时，返回 404 Not Found；当账号被锁定时，返回 423 Locked；当密码错误但尚未达到锁定阈值时，返回 401 Unauthorized。登录成功后，AuthService 会生成包含 user_id、role_type 和过期时间的 Token，由 WebInterface 保存到浏览器安全存储区，并根据角色类型将用户路由到对应工作台。Token 续期与退出登录流程也通过 AuthService 完成，保证后续功能调用均建立在统一鉴权机制上。

2. 批量检索与异步任务轮询流程

批量检索与异步任务轮询协作图展示了系统在处理大规模查询任务时的后台协作结构。API-Client 将多条查询向量、检索参数和目标索引 ID 封装为批量请求提交给 TaskQueue。TaskQueue 不直接执行检索，而是先在 TaskDB 中创建批量任务记录，生成 batch_task_id，并向客户端返回 202 Accepted。这样可以避免客户端长时间阻塞，也使后端能够以异步方式调度资源。

任务入队后，TaskQueue 将批量任务拆分为多个子任务，并分发给 SearchWorker 并行执行。

每个 SearchWorker 从 VectorDB 获取归一化参数,对查询向量进行对齐处理,再调用 annSearch 执行近似最近邻检索。子任务完成后,SearchWorker 将 Top-K 结果、距离分值、元数据标签和执行耗时写入 TaskDB。客户端则通过 GET /tasks/batch_task_id 按指数退避策略轮询任务状态,直到所有子任务完成或失败。最终 TaskQueue 汇总子任务结果,形成完整的 result_json,供 APIClient 下载并写入后续分析流水线。

3. 单细胞相似性检索流程

单细胞相似性检索协作图展示了系统面向普通用户的在线检索调用链。用户在 Web 前端输入查询细胞编号或查询向量,并设置 Top-K、元数据过滤条件和目标索引 ID。WebInterface 将请求发送至 SearchEngine,SearchEngine 先解析 Token 并完成权限校验,确保用户只能访问其权限范围内的数据集或公共数据库。

在检索阶段,SearchEngine 首先向 VectorDB 获取目标索引对应的归一化参数,并对查询向量进行对齐和维度校验。校验通过后,系统同时执行两条路径:一条路径调用 VectorDB 进行 ANN 粗筛,获取 Top-Kx2 的候选细胞集合;另一条路径调用 MetaDB 根据组织类型、测序平台等标量条件执行过滤。SearchEngine 对两路结果进行位图交集运算后,再从 VectorDB 读取候选细胞的原始向量,执行距离计算与重排序,截取最终 Top-K。最后,SearchEngine 从 MetaDB 获取细胞类型、组织来源、供体编号和可视化坐标等信息,将结果封装后返回 WebInterface,由前端渲染结果表格和 UMAP 可视化图。

4. 数据预处理与向量入库流程

数据预处理与向量入库协作图展示了系统从原始单细胞文件到可检索向量的生产链路。用户通过 WebInterface 上传.h5ad 或.loom 格式文件,Web 前端采用分块上传机制将文件提交给 DataProcessor。DataProcessor 接收文件后,首先完成格式校验,包括解析文件头、检查矩阵维度、验证基因列表和细胞编号的完整性,并将数据集基本信息写入 Database。

格式校验通过后,DataProcessor 进入生物学层面的质量控制阶段,依次完成空细胞过滤、双细胞检测、线粒体基因占比计算等操作,并将通过质控的细胞元数据写入数据库。随后系统执行库大小归一化、对数转换、高变基因选择和降维处理,将原始高维稀疏矩阵转换为固定维度的稠密向量。生成的 embedding_data、dimension、reduction_method 和 normalization_params 会被批量写入 cell_vectors 表。最后,WebInterface 向用户展示预处理质量报告,用户确认无误后,系统将数据集状态更新为 Preprocessed,为后续 ANN 索引构建提供输入。

5. ANN 索引构建与热加载流程

ANN 索引构建与热加载协作图展示了系统索引生命周期管理中的对象协作。管理员在后台配置索引算法类型、距离度量方式、超参数和目标数据集 ID 后,SystemController 在 VectorDB 中创建索引记录,并将 build_status 初始化为 Building。随后 SystemController 将构建任务异步提交给 IndexBuilder,并向管理员返回 task_id。

IndexBuilder 从 VectorDB 批量读取目标数据集的 embedding_data,并根据当前服务器硬件环境选择合适的构建算子。对于 HNSW 类型索引,系统主要执行近邻图分层构建和边连接优

化; 对于 IVF_PQ 类型索引, 系统执行聚类中心计算和乘积量化压缩。构建过程中, IndexBuilder 周期性向 SystemController 汇报进度, 由 SystemController 推送到管理员监控界面。索引构建完成后, IndexBuilder 将索引文件保存到磁盘, 更新 index_file_path、memory_usage 等信息, 并执行召回率验证。若召回率达标, 索引状态更新为 Ready; 若不达标, 则状态置为 Error, 并返回诊断报告。

当 SystemController 收到 Ready 状态后, 会通知 SearchService 执行热切换。SearchService 通过原子句柄替换机制将旧索引引用切换为新索引引用, 保证正在进行的检索请求不受影响。切换完成后, 系统记录索引上线日志, 并向管理员推送成功通知。旧索引会在确认没有请求引用后被延迟回收, 保证在线检索服务的连续性和内存使用的安全性。

七、 状态图

(一) 状态图简介

状态图从动态行为视角描述系统的控制流转，定义了系统内核心业务对象在其生命周期内经历的各类状态、状态变量以及触发状态迁移的事件与动作，确立了整个软件工程的逻辑执行骨架。由于单细胞数据检索涉及复杂的异步调用与多阶段的算法处理，状态图可以清晰界定“核心检索任务如何响应外部请求”以及“系统在不同计算阶段如何进行状态调度与演化”。我们识别关键的生命周期阶段并捕捉其并发与同步机制，确保系统在处理海量高维稀疏向量查询时，底层的事件驱动模型与状态变迁逻辑能够直接支撑业务侧对高可靠性与低延迟的需求。

在核心状态的界定上，本项目根据实际任务执行的生命周期将其划分为并发准备节点、算法调度节点与条件组装节点。任务初始化（含字段分配与授权校验活动）构成了系统接入的起点，拦截非法访问；随后，系统通过并发分劈进入记录系统日志与文本清洗预处理的并行状态组，这极大地提高了业务吞吐表现。此外，通过标准的信号发送与接收机制，完成与外部大模型代理的特征嵌入交互，并平滑过渡到最核心的 ANN 检索执行状态。这些流转将分布式通信、内存计算与并发处理深度绑定，要求系统具备高容错的异步非阻塞调度能力。

状态图可以通过明确的并发分劈/接合边界与严谨的菱形分支判定，将底层繁杂的线程回调细节与具体的异步 IO 逻辑进行抽象封装，而将核心关注点锁定在“请求初始化、并行日志预处理、大模型信号交互及多维检索渲染”这一高度内聚的状态演化拓扑中。这使得开发团队在实现任务调度引擎时，能集中精力优化核心状态的流转效率、保证并发安全性以及处理异常回滚，而不会陷入混乱的局部控制流与“面条式代码”泥潭中。

在本项目的设计方案中，状态图中定义的每一个三段式状态与其包含的进入机制及活动（do/活动），都将转化为后端代码中的状态机模式或异步消息工作流。并发与接合线条将严格映射为后端的协程池并行调度与阻塞等待机制，信号收发则对应微服务间的 RPC 调用或消息队列事件。我们能够借此验证动态业务流是否足够健壮以处理边界异常，并是否防范了并发竞态与死锁问题。本章节的状态图既是后期事件总线搭建与调度器编写的行为蓝图，也是检验整个系统“流转合理性”与“时序正确性”的基石准则

(二) 状态图构建




图 22: 单细胞特征检索系统 - 标准组件化状态图

(三) 状态图解释

如图 22 所示，该状态图依据 UML 标准详细刻画了“检索任务 (SearchTask)”在单细胞特征检索系统中的完整动态生命周期。任务从黑色的“起始状态”进入“任务初始化”，完成基础授权与格式校验。随后，为了提升系统吞吐性能，控制流通过一根粗横线（并发分劈，Fork）分裂为两条并行的子状态路径，即“记录系统日志”与“文本预处理”；这两步操作各自维护独立的内部状态变量后，再通过下方的粗横线（并发接合，Join）重新同步。这种设计清晰地反映了系统在实际执行过程中的多线程异步调度逻辑。

在并发汇合之后，系统进入图中的特殊信号转换阶段。通过标准的外凸与内凹信号图形，状态图直观展示了系统向外部大模型代理发送文本，并阻塞接收高维特征稠密向量的过程。获取向量后，任务平滑过渡到“ANN 检索执行”这一核心运算状态。值得注意的是，检索完成后存在一个菱形“条件判定”结构：若当前请求为常规查询，任务将直接流向右侧整合 JSON 并结束；

若触发了“需可视化”条件，则流向左侧的分支状态，额外执行 UMAP 的“结果降维渲染”操作。整个图符完整运用了三段式状态框、并发横杠与事件信号标记，精准地捕获了异常复杂的异步处理流程直至最终平稳达到终端靶心状态的全阶段脉络态的生命周期全貌。

八、 构件图

(一) 构件图简介

构件图从物理实现与部署的宏观视角描述系统的架构结构，定义了系统内部各个可独立替换的模块实体（Components）、接口契约以及构件间的依赖关系，确立了整个软件工程的服务边界。由于单细胞特征检索系统涉及高并发查询与高维度向量计算，构件图可以清晰界定“系统由哪些核心物理模块构成”以及“模块间如何通过服务契约进行通信与解耦”。我们识别关键的物理构件并捕捉其调用链路，确保系统在处理底层大语言模型接入与海量数据检索时，各计算模块的职责能够直接支撑系统的分布式部署与高可用需求。

在核心构件的界定上，本项目根据实际服务职能与其在端到端链路中的位置，将其划分为前端交互层、业务引擎层与底层支撑层。Web 界面（WebInterface）、API 客户端（APIClient）与管理员界面（AdminInterface）构成了系统的接入载体，完整接管了不同用户角色的请求接入与数据可视化呈现。而数据处理模块（DataProcessor）、搜索引擎（SearchEngine）与向量数据库（VectorDB）则属于核心运算与存储支撑实体，将经外部大语言模型转换后的稠密特征数据与底层的近似最近邻查询能力深度绑定，要求系统提供具备高吞吐响应与低延迟检索特性的服务体系。

构件图可以通过明确的“提供接口（Provides）”与“依赖接口（Requires）”契约，将底层复杂的分布式协同与负载均衡细节进行合理的面向服务封装，而将核心关注点锁定在“单次/批量检索、特征嵌入、数据库状态监控”这一高度自治的服务解耦拓扑中。这使得架构团队在部署系统底座时，能集中精力优化核心构件的网络通信效率以及大模型调用的异步处理，而不会陷入单一代码逻辑的内部耦合中。

在本项目的设计方案中，构件图中定义的每一个模块与其暴露的接口协议，都将转化为实际部署环境中的微服务容器或独立进程，构件之间的依赖与被依赖关系，最终严格映射为系统服务间的 RPC 调用或 RESTful API 契约网络。我们能够借此验证物理架构是否足以支撑海量请求的并发分发，并是否满足了系统高扩展性的隔离指标。本章节的构件图既是后期系统集成与持续部署（CI/CD）的物理蓝图，也是检验整个系统“模块独立性”与“服务健壮性”的基石准则。

(二) 构件图构建




图 23: 单细胞特征检索系统 - UML 构件图

(三) 构件图解释

如图 23 所示,本系统的构件图采用了现代 UML 2.0 的构件图样式与经典的棒棒糖(Lollipop)表示法相结合,清晰地勾勒了单细胞特征检索系统内部各物理模块的服务提供与依赖关系。图中的核心运算节点 SearchEngine (搜索引擎) 作为整个系统的中枢,向下通过虚线箭头 (Requires) 依赖 DataProcessor 提供的 embedData (特征嵌入) 接口和 VectorDB 提供的 vectorQuery (向量查询) 接口;同时,它向左通过实线 (Provides) 暴露出 singleSearch (单次检索)、visSearch (可视化检索) 及 batchSearch (批量检索) 三个核心服务接口,有效实现了底层算法逻辑与上层业务请求的物理隔离与解耦。

在外部交互层面上,图示直观地展现了系统如何对接不同的外部实体与用户角色。针对运维需求, AdminInterface 构件直接依赖 VectorDB 暴露的 dbStatus 接口,以便系统管理员进行底层数据库状态的实时监控;而在用户端,基础研究员通过 WebInterface 接入系统,算法工程师则通过 APIClient 进行交互,二者均通过安全合规的依赖链路调用中枢检索引擎暴露的服务接口。此外,系统顶层的外部大模型代理直接与 DataProcessor 构件对接,保障了多模态数据向系统内部输入通道的高效流转。这种明确的接口契约划分,确保了系统能够在高并发场景下维持各个模块的独立调度与灵活扩展。

九、部署图

(一) 部署图简介

部署图从物理拓扑视角描述系统的运行期架构，定义了系统内软硬件节点（Nodes）、计算资源分布以及分布在各个环境上的软件可执行制品（Artifacts），确立了整个软件工程的物理承载与运行基座。由于单细胞数据检索涉及海量高维向量对齐与复杂的大模型推理计算，部署图可以清晰界定“系统由哪些异构计算硬件构成”以及“进程模型在分布式网络间如何调度与通信”。我们识别关键的主机设施并捕捉其网络依赖，确保系统在处理并发千万级细胞特征查询时，底层的集群拓扑与通信链路能够直接支撑业务侧对高并发量与低延迟的严苛需求。

在核心物理节点的界定上，本项目根据实际算力需求与运行环境特征将其划分为通用业务调度集群与专有计算/存储底座。应用服务器（Linux CentOS）构成了系统的中枢控制载体，在其内集中部署了搜索引擎（SearchEngine.jar）、数据处理器（DataProcessor.jar）以及 Web 与后台服务应用（WebInterface.war / AdminInterface.war），完整承载了从请求解析到检索调度的核心业务流。而向量数据库节点（Ubuntu）与大模型服务集群（GPU 阵列）则属于强隔离的异构支撑节点，将核心底层特征的数据载体（VectorDB.data）与硬件加速代理程序（LLMProxy.exe）深度绑定，要求物理层提供具备高吞吐 I/O 特性与强劲并行张量计算能力的专属硬件结构。

部署图可以通过明确的网络划分与节点边界，将底层繁杂的环境配置细节与具体的软件内部代码逻辑进行合理的架构级解耦，而将核心关注点锁定在“客户端、应用中心、数据底座及 AI 算力”这一高度分布式的物理拓扑中。这使得运维与开发团队在搭建系统基座时，能集中精力优化跨节点的通信协议栈与带宽分配——外部终端通过安全的 HTTPS/REST/WSS 协议接入，内部数据存取采用极低延迟的 TCP/IP 高速内网连接，而大模型推理则依赖于高效的 RPC 长连接进行远程过程调用，从而避免开发团队陷入无关的硬件环境碎片细节中。

在本项目的设计方案中，部署图中定义的每一个物理节点及其承载的软件制品，都将转化为实际生产环境中的云服务器实例、容器化配置或裸金属 GPU 主机，节点与节点间的关联连线最终将严格映射为机房中的防火墙规则、负载均衡与 VPC 路由体系。我们能够借此验证物理架构是否足以支撑构件图与顺序图中的逻辑调用压力，并是否满足了最初高可用集群的性能指标。本章节的部署图既是后期运维配置、容器编排与系统发布的落地蓝图，也是检验整个系统“拓扑合理性”与“硬件资源完备性”的基石准则。

(二) 部署图构建




图 24: 单细胞特征检索系统 - UML 部署图

(三) 部署图解释

系统采用了具有高度扩展性的分布式网络架构，以运行 Linux CentOS 的应用服务器为绝对的业务调度中枢。该物理节点内部集中部署了系统的四大核心可执行制品（WebInterface.war、AdminInterface.war、SearchEngine.jar 以及 DataProcessor.jar），不仅负责接收和解析来自外界的访问请求，也是连接底层高维向量数据库与大模型推理算力的核心控制大脑。

该部署图明确界定了另外三大外围异构节点的功能边界与网络通信协议。左侧的用户终端（Windows/Mac）承载了浏览器与 API 客户端，通过安全的 HTTPS/REST/WSS 协议接入控制中心；右侧专用的向量数据库节点（Ubuntu 环境）运行 VectorDB 数据基座，通过低延迟的 TCP/IP 高速内网与应用服务器互联，保障海量细胞特征向量的极速读写；位于上方的大模型服务集群（GPU 阵列）则作为算力支撑，运行 LLMProxy 制品，并通过高效的 RPC 远程调用协议与应用服务器实时通信，专属负责计算密集型的特征提取与大语言模型推理任务。